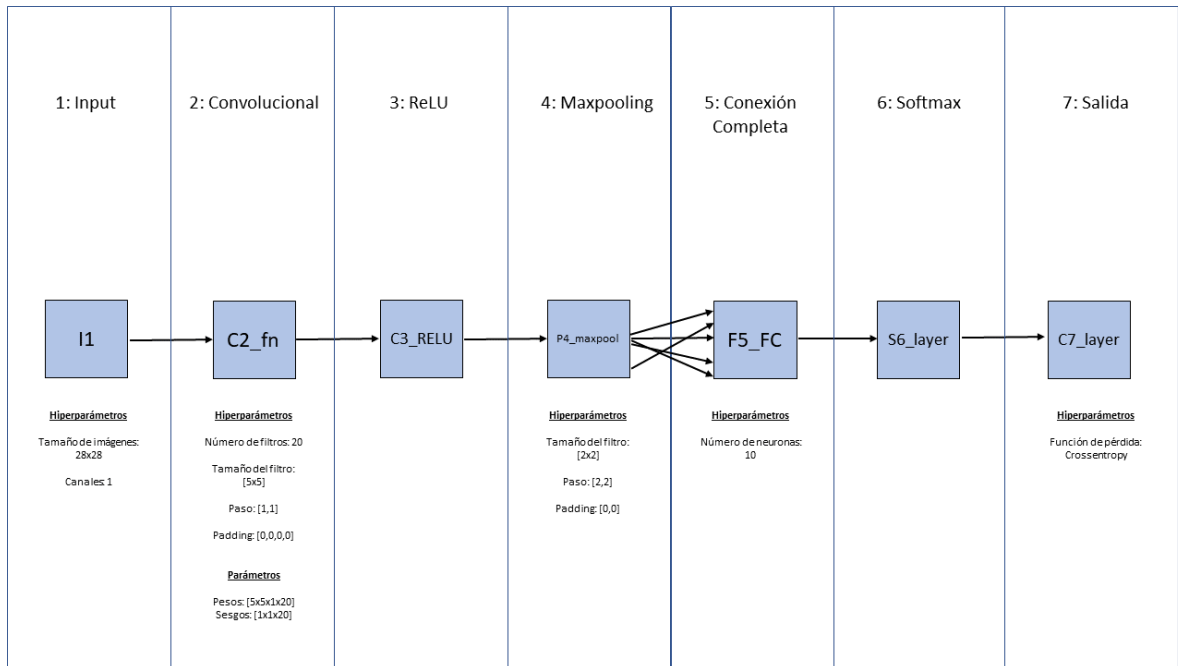


# Práctica de Redes de Convolución

Juliana Quirós, Alberto

1.




2.1.


Estas fueron las tasas probadas:

tasa	exactitud
1e-05	36.76
1e-04	83.88
1e-03	96.08
1e-02	10.00
1e-01	10.00

La em es de 96.08%, con una tm=0.001.



2.2



Medias de exactitud por épocas:

exactitud_10	exactitud_20	exactitud_30	exactitud_40	exactitud_50
55.09333	60.03111	60.84889	59.80444	61.84444

### 2.3


Como podemos observar, obtenemos una mayor exactitud con tasas de aprendizaje más pequeñas que con múltiplos de la máxima. Esto puede deberse a que el algoritmo converge en una solución subóptima (mínimo local) en los primeros casos, frente a la omisión directa de dichos mínimos en los segundos casos, que inducen errores de detección y clasificación.

Observamos a su vez, que la tasa que da lugar a la exactitud máxima se mantiene hasta llegar a 30 épocas. A partir de las 40,  $tm/5$  supera ligeramente a  $tm$ . Este fenómeno se debe a que el algoritmo ha dispuesto de mayor tiempo de entrenamiento.

La media de exactitud más alta (61.8444) se produce con 50 iteraciones, lo cual confirma lo anteriormente expuesto.

### 3.1

Basándome en el ejercicio anterior, empleo  $tm/5$  (0.0002) y 50 épocas:

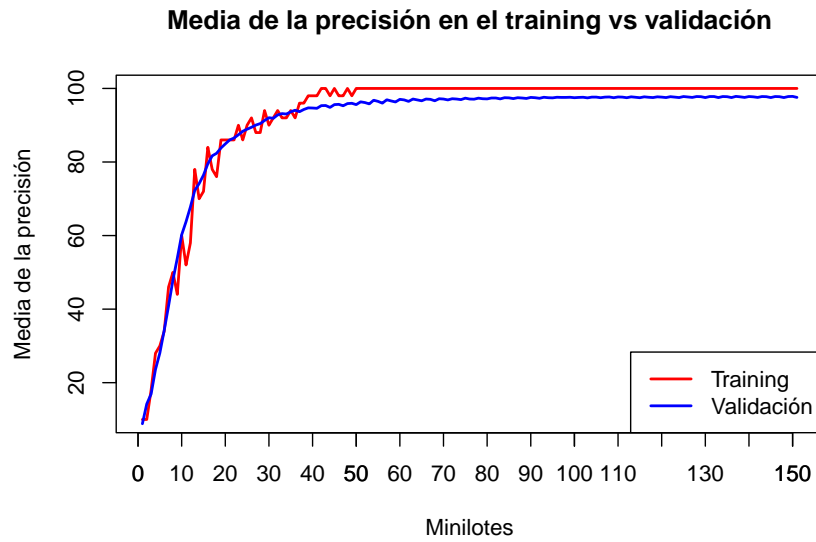


### 3.2

Empleo la prueba no paramétrica de los signos para 2 muestras, dado que tanto las distribuciones de exactitudes de validación como la de las medias de exactitudes de entrenamiento son muy asimétricas.

```
##
## Wilcoxon rank sum test
##
## data: med_train and val_acc
## W = 17805, p-value < 2.2e-16
## alternative hypothesis: true location shift is not equal to 0
```

Por lo tanto, con un 95% de confianza rechazo la  $H_0$  de igualdad de medianas, por lo que existe evidencia estadística de sobreajuste.



Podemos observar como a partir de, aproximadamente, el minilote 36 (iteración 5400), comienzan a separarse ambos conjuntos de forma sistemática.

#### 4.2

MNIST-MNIST (tm/5 (0.0002),50 épocas, 750 imágenes de training, 100 de test, tamaño de minilote: 50, frecuencia de validación = 50):

Exactitud = 97 %

Matriz de confusión:

10	0	0	0	0	0	0	0	0	0
0	10	0	0	0	0	0	0	0	0
0	1	9	0	0	0	0	0	0	0
0	0	0	10	0	0	0	0	0	0
0	0	0	0	10	0	0	0	0	0
0	0	0	0	0	10	0	0	0	0
0	0	0	0	1	0	9	0	0	0
0	1	0	0	0	0	0	9	0	0
0	0	0	0	0	0	0	0	10	0
0	0	0	0	0	0	0	0	0	10

MNIST-base propia (tm/5 (0.0002),50 épocas, 750 imágenes de training, 100 de test, tamaño de minilote: 50, frecuencia de validación = 50):

Exactitud = 22 %

Matriz de confusión:

5	0	1	1	0	1	0	1	0	1
1	4	0	0	0	0	2	2	0	1
1	1	3	0	0	0	2	0	2	1
1	1	2	1	0	0	1	1	2	1
1	3	3	0	1	1	0	0	1	0
0	1	2	1	0	1	3	1	1	0
1	1	2	0	0	0	1	4	1	0
1	0	0	4	0	0	2	2	1	0
2	2	1	0	0	1	0	0	4	0
1	1	2	2	1	0	0	3	0	0

#### 4.3

Base propia-MNIST (tm/5 (0.0002),50 épocas, 100 imágenes de training, 100 de test, tamaño de minilote: 5, frecuencia de validación = 5):

Exactitud = 10 %

Matriz de confusión =

1	0	7	0	0	0	0	2	0	0
0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0

Base propia-Base Propia (tm/5 (0.0002),50 épocas, 100 imágenes de training, 100 de test, tamaño de minilote: 5, frecuencia de validación = 5):

Exactitud = 30%

Matriz de confusión =

0	0	1	0	0	0	0	0	0	0
1	1	0	0	0	0	0	0	0	0
0	0	1	0	0	0	0	0	0	0
0	0	0	0	0	0	1	0	0	0
0	0	0	0	1	0	0	0	0	0
0	0	1	0	0	0	0	0	0	0
0	0	1	1	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0
0	0	0	1	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0