Práctica de Redes de Convolución

Juliana Quirós, Alberto

07/04/2023

1.

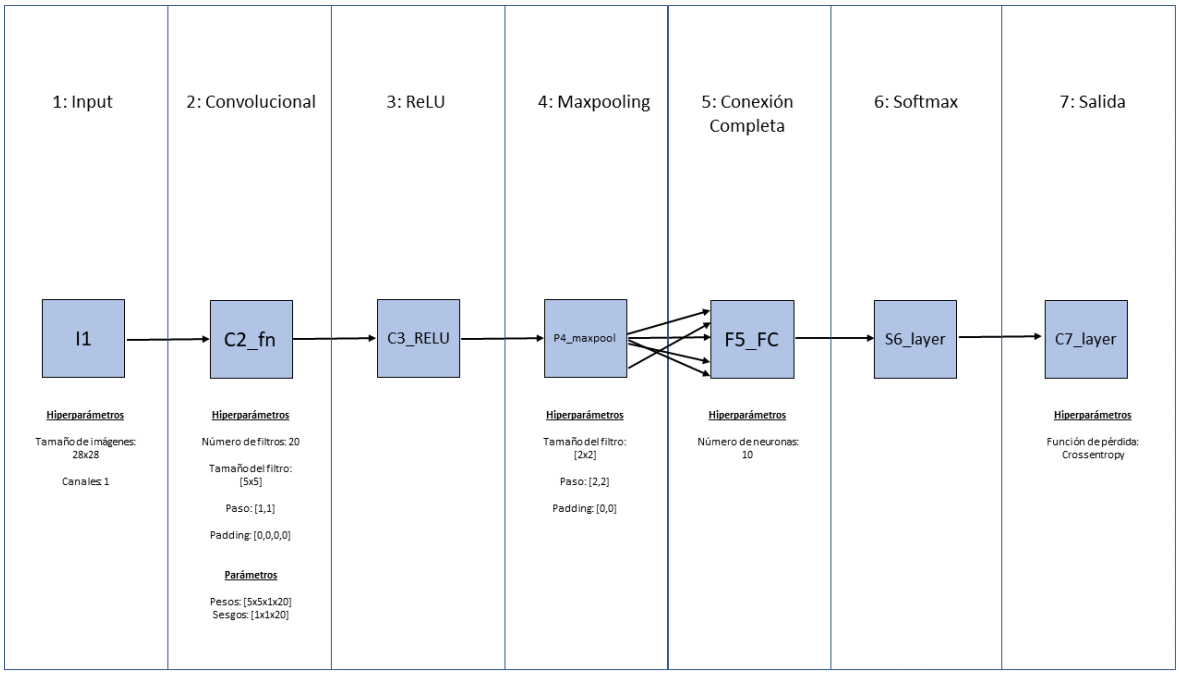

2.1.
Estas fueron las tasas probadas:

tasa	exactitud
1e-05	36.76
1e-04	83.88
1e-03	96.08
1e-02	10.00
1e-01	10.00

La em es de 96.08%, con una tm=0.001.

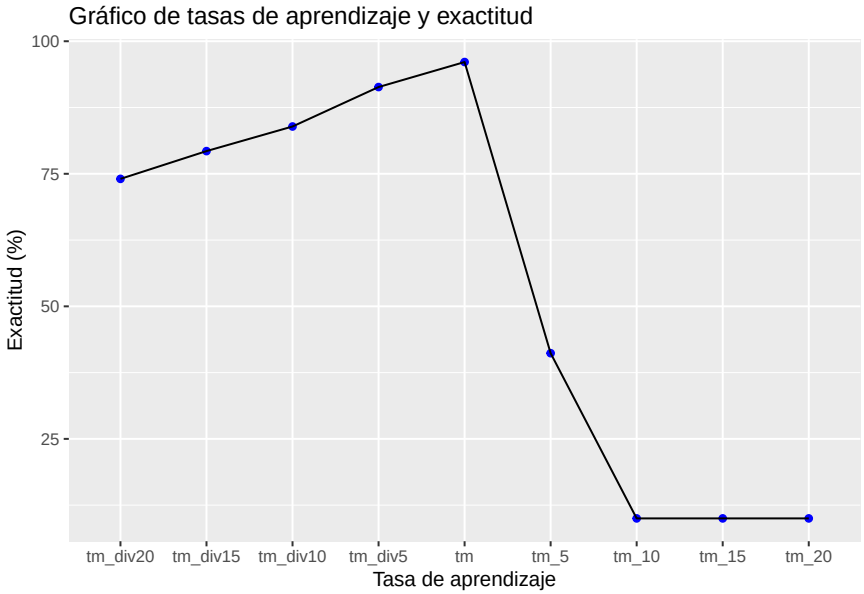

2.2

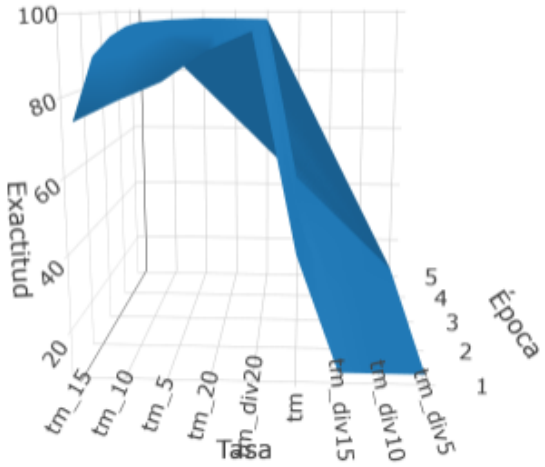

Medias de exactitud por épocas:

exactitud_10	exactitud_20	exactitud_30	exactitud_40	exactitud_50
55.09333	60.03111	60.84889	59.80444	61.84444

2.3
Como podemos observar, obtenemos una mayor exactitud con tasas de aprendizaje más pequeñas que con múltiplos de la máxima. Esto puede deberse a que el algoritmo converge en una solución subóptima (mínimo local) en los primeros casos, frente a la omisión directa de dichos mínimos en los segundos casos, que inducen errores de detección y clasificación.

Observamos a su vez, que la tasa que da lugar a la exactitud máxima se mantiene hasta llegar a 30 épocas. A partir de las 40, tm/5 supera ligeramente a tm. Este fenómeno se debe a que el algoritmo ha dispuesto de mayor tiempo de entrenamiento.

La media de exactitud más alta (61.8444) se produce con 50 iteraciones, lo cual confirma lo anteriormente expuesto.

3.1
Basándome en el ejercicio anterior, empleo tm/5 (0.0002) y 50 épocas:

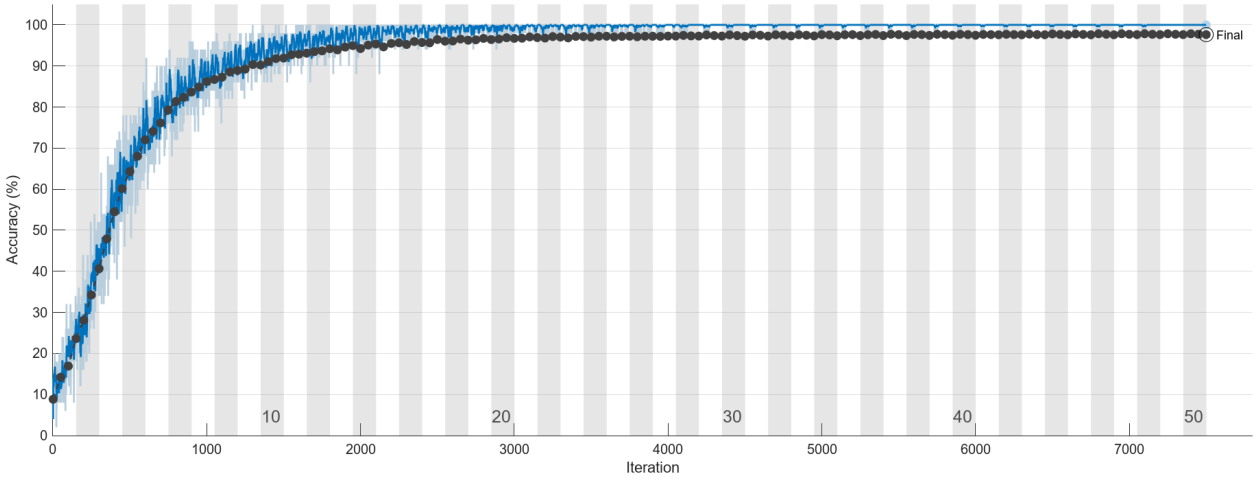

3.2

Empleo la prueba no paramétrica de los signos para 2 muestras, dado que tanto las distribuciones de exactitudes de validación como la de las medias de exactitudes de entrenamiento son muy asimétricas.

```
##
##  Wilcoxon rank sum test
##
## data:  med_train and val_acc
## W = 17805, p-value < 2.2e-16
## alternative hypothesis: true location shift is not equal to 0
```

Por lo tanto, con un 95% de confianza rechazo la H0 de igualdad de medianas, por lo que existe evidencia estadística de sobreajuste.

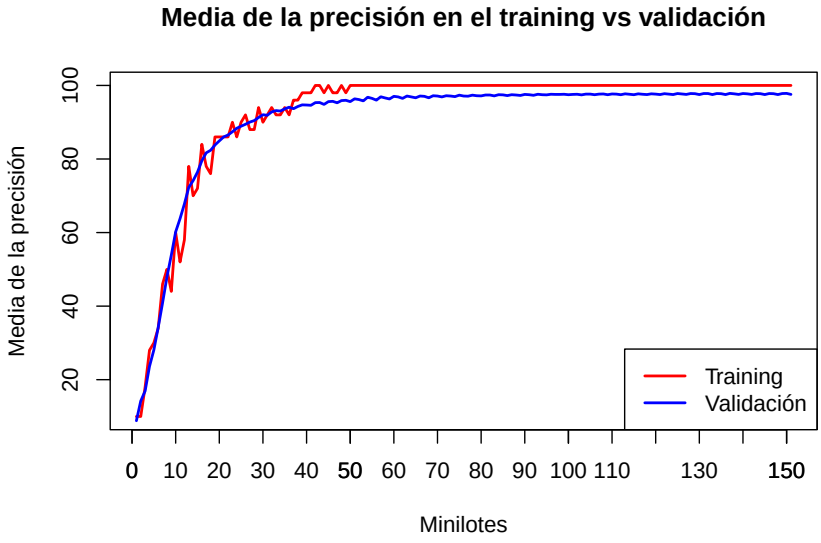

Podemos observar como a partir de, aproximadamente, el minilote 36 (iteración 5400), comienzan a separarse ambos conjuntos de forma sistemática.

4.2
MNIST-MNIST (tm/5 (0.0002),50 épocas, 750 imágenes de training, 100 de test, tamaño de minilote: 50, frecuencia de validación = 50):
Exactitud = 97 %
Matriz de confusión:

10	0	0	0	0	0	0	0	0	0
0	10	0	0	0	0	0	0	0	0
0	1	9	0	0	0	0	0	0	0
0	0	0	10	0	0	0	0	0	0
0	0	0	0	10	0	0	0	0	0
0	0	0	0	0	10	0	0	0	0
0	0	0	0	1	0	9	0	0	0
0	1	0	0	0	0	0	9	0	0
0	0	0	0	0	0	0	0	10	0
0	0	0	0	0	0	0	0	0	10

MNIST-base propia (tm/5 (0.0002),50 épocas, 750 imágenes de training, 100 de test, tamaño de minilote: 50, frecuencia de validación = 50):
Exactitud = 22 %
Matriz de confusión:

5	0	1	1	0	1	0	1	0	1
1	4	0	0	0	0	2	2	0	1
1	1	3	0	0	0	2	0	2	1
1	1	2	1	0	0	1	1	2	1
1	3	3	0	1	1	0	0	1	0
0	1	2	1	0	1	3	1	1	0
1	1	2	0	0	0	1	4	1	0
1	0	0	4	0	0	2	2	1	0
2	2	1	0	0	1	0	0	4	0
1	1	2	2	1	0	0	3	0	0

4.3
Base propia-MNIST (tm/5 (0.0002),50 épocas, 100 imágenes de training, 100 de test, tamaño de minilote: 5, frecuencia de validación = 5):
Exactitud = 10 %
Matriz de confusión =

1	0	7	0	0	0	0	2	0	0
0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0

Base propia-Base Propia (tm/5 (0.0002),50 épocas, 100 imágenes de training, 100 de test, tamaño de minilote: 5, frecuencia de validación = 5):
Exactitud = 30%
Matriz de confusión =

0	0	1	0	0	0	0	0	0	0
1	1	0	0	0	0	0	0	0	0
0	0	1	0	0	0	0	0	0	0
0	0	0	0	0	0	1	0	0	0
0	0	0	0	1	0	0	0	0	0
0	0	1	0	0	0	0	0	0	0
0	0	1	1	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0
0	0	0	1	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0

4.4
Extraigo los pesos de entrenamiento por medio de:

```
writematrix(C2_layer.Weights,"pesos_44X.csv")
```

E inicializo las redes con esos nuevos pesos

MNIST-base propia (tm/5 (0.0002),50 épocas, 750 imágenes de training, 100 de test, tamaño de minilote: 50, frecuencia de validación = 50):
Exactitud = 26%

Se ha mejorado la exactitud en un 4%.

Base propia-Base Propia (tm/5 (0.0002),50 épocas, 100 imágenes de training, 100 de test, tamaño de minilote: 5, frecuencia de validación = 5):
Exactitud = 30%
No se ha mejorado la exactitud.

4.5
En cuanto al 4.2, podemos comprobar cómo el emplear la base de datos propia como test disminuye la exactitud, a pesar de haber igualado las condiciones al testeo con MNIST. Esto puede haberse debido a un fallo propio en el proceso de normalización de las imágenes a un formato similar al de la base original.

Por otra parte, en el 4.3, la baja exactitud con MNIST puede deberse nuevamente a la normalización o falta de entrenamiento. Observamos cómo la mayor exactitud se da entre base propia-base propia, lo cual tiene sentido dado que se testea y entrena con la misma base. A su vez, se da un acuciado overfitting.

Finalmente, en 4.4, la no mejora de exactitud entre base propia-base propia puede encontrar su explicación en la falta de entrenamiento, dado que al emplear MNIST como entrenamiento sí que mejora.

ANEXO: Código empleado en 4.4. (base propia-base propia)

```
%
%              RED NEURONAL DE CONVOLUCIÓN
%
%           EJEMPLO de CLASE (2023). Luis Jáñez. UCM
%
%
%
%          ENTRADAS:    Imagenes de numeros escritos a mano
%
%          SALIDAS:     Numero reconocido
%
% ********************************************************************
% REQUISITOS PARA LA EJECUCIÓN DE ESTE PROGRAMA
%
% En las versiones nuevas de Matlab (R2020 y siguientes) basta tener
% instalada la Toolbox Deep Learning.
%


% ********************************************************************
%  Autor: Luis Jáñez Escalada
% (C) 2018-23  Luis Jáñez Escalada
% ********************************************************************



%%%%%%%% iniciar programa

global plotObj
clearvars
```

```
%clc

% Iniciar cronómetro para medir el tiempo de ejecución del programa
datetime
tic
timerVal_60 = tic

% Cerrar todas las ventanas abiertas en ejecuciones previas
close all
close all hidden

% abre y cierra todos los ficheros
fopen('all');
fclose ('all');




%**************************************************************************
%**************************************************************************
%
%      1. ESTABLECE, CARGA Y REVISA LA BASE DE IMÁGENES A UTILIZAR
%
%**************************************************************************
%**************************************************************************


%  1.1. ESTABLECE LA BASE DE IMÁGENES A UTILIZAR
%**************************************************************************

% BaseImagenesYaDisponible=1;
%  IMAGE BASE digitData CONTENT: 10 000 IMAGES, each having  28x28x1 pixels
%
% 10×2 table
%     Label    Count
%     _____    _____
%     0        1000
%     1        1000
%     2        1000
%     3        1000
%     4        1000
%     5        1000
%     6        1000
%     7        1000
%     8        1000
%     9        1000

% UBICACIÓN donde se  hallan las imágenes

digitDatasetPath = fullfile(matlabroot,'toolbox','nnet','nndemos', ...
        'nndatasets','DigitDataset');
% digitDatasetPath =
%     'C:\Program Files\MATLAB\R2018a\toolbox\nnet\nndemos\nndatasets\DigitDataset'
```

```
digitData = imageDatastore(digitDatasetPath, ...
        'IncludeSubfolders',true,'LabelSource','foldernames');

 %% defino mi base custom
baseCustomPath = fullfile(matlabroot,'toolbox','nnet','nndemos', ...
        'nndatasets','base_custom');
baseCustom = imageDatastore(baseCustomPath, ...
        'IncludeSubfolders',true,'LabelSource','foldernames');




%  1.2. SEPARA LAS MUESTRAS DE APRENDIZAJE Y DE TEST
%**************************************************************************

% Divide the data into training and test sets, so that each category in
% the training set has 750 images and the test set has the remaining images
% from each label.

trainingNumFiles = 10;
rng(1) % For reproducibility
% splitEachLabel splits the image files in digitData into two new datastores,
% trainDigitData and testDigitData.
%[trainDigitData,testDigitData] = ...
    %splitEachLabel( digitData, trainingNumFiles, 'randomize' )  ;
    %% Definir nuevos train y test
    trainDigitData = subset(baseCustom, randperm(length(baseCustom.Files), trainingNumFiles));
    testDigitData = subset(baseCustom, randperm(length(baseCustom.Files), trainingNumFiles));


%**************************************************************************
%**************************************************************************
%
%                    2. CREAR LA RED CONVOLUCIONAL
%
%**************************************************************************
%**************************************************************************



%
% 2.1.  DEFINIR LAS 7 CAPAS QUE VAN A INEGRAR LA RED
% ************************************************

%  ------
%  CAPA 1
%  ------

% C1: capa de entrada

% GUIA en https://es.mathworks.com/help/nnet/examples/create-simple-deep-learning-network-for-classific

% I1_layer
```

```
I1_nrows=28; % nº de filas
I1_ncols=28; % nº de columnas
I1_nchan=1;  % nº de canales
I1_nn= I1_nrows*I1_ncols*I1_nchan; % number of outputs or neurons
I1_layer= imageInputLayer([I1_nrows I1_ncols I1_nchan],...
  'Name','I1_layer',...
  'Normalization','none');
%   'DataAugmentation','randcrop',...
%   'DataAugmentation','randfliplr',...


%  ------
%  CAPA 2
%  ------

% C2: capa convolucional

C2_fn=20; % nº de filtros
C2_ks=[5 5] ; % tamaño del núcleo
%C2_nn= C2_fn * ()
C2_layer = convolution2dLayer(C2_ks, C2_fn,...
    'Name','C2_fn',...
    'WeightLearnRateFactor',1,...
    'BiasLearnRateFactor',1,...
    'Stride',[1,1],...
    'Padding' ,[0,0],...
    'NumChannels','auto',...
    'WeightL2Factor',1,...
    'BiasL2Factor', 1) ;
% % %     'WeightLearnRateFactor',0.0001,...

% C2 initialization
    % The default for the initial weights is a Gaussian distribution
    % with mean 0 and standard deviation 0.01.
    % The default for the initial bias is 0.
    % You can manually change the initialization for the weights and bias.
    % See Specify Initial Weight and Biases in Convolutional Layer EN
    % https://es.mathworks.com/help/nnet/ref/convolution2dlayer.html#bu7fl4y-1 .
% initial standard deviation for weights and biases
%%C2_SDinitWeights=0.01 ;
% Manually initialize the weights from a Gaussian distribution with standard deviation of 0.0001.
%%C2_layer.Weights =  randn([C2_ks(1) C2_ks(2) I1_nchan C2_fn]) * C2_SDinitWeights ;
%% Especifico los pesos basándome en el entrenamiento:
pesos = readmatrix("pesos_442.csv");
 C2_layer.Weights = reshape(pesos, 5,5,1,20);

% Crea la imagen de los pesos iniciales , la amplia y la pinta en la pantalla.

% Obtiene y pinta los pesos iniciales asignados

w1 = C2_layer.Weights;
% Scale and resize the weights for visualization
w1 = mat2gray(w1);
```

```
% amplia 4 veces la imagen para verla más grande en la pantalla
w1x4(:,:,1,:) = imresize(w1(:,:,1,:),4,'Method','nearest');
% w1(1,:,3,2)   (columna, fila, profundidad, nº de feature map)
figure
montage(w1x4,'BorderSize',[1 1],'BackgroundColor','yellow' )
title('FILTROS INICIALES EN CAPA CONVOLUCIONAL zoom x 4')


%  ------------------------------------------------
%  CAPA 3       R3: capa de rectificación lineal
%  ------------------------------------------------

R3_layer = reluLayer('Name','C3_RELU');



%  ------------------------------------------------
%  CAPA 4     P4 MaxPooling
%  ------------------------------------------------

P4_ks   = [2 2]; % kernel size
P4_stride   = [2 2];
P4_pad   = [0 0];  %=ceil((S4_is - P4_ks + 1) ./ P4_ss);
P4_layer =maxPooling2dLayer(P4_ks,...
    'Name','P4_maxpool',...
    'Stride',P4_stride,...
    'Padding',P4_pad);



%  ----------------------------------------
%  CAPA 5    F5:  capa de conexión completa
%  ----------------------------------------

% F5 layer fullyConnectedLayer(10)
F5_s=10; % nº de neuronas en la capa
%%% F5_layer = fullyConnectedLayer(F5_s) ;
F5_layer = fullyConnectedLayer(F5_s, ...
    'Name','F5_FC', ...
    'WeightLearnRateFactor',1,...
    'BiasLearnRateFactor',1) ;



%  ----------------------------------------
%  CAPA 6     S6:  capa softmax
%  ----------------------------------------

%S6 SoftMax layer
S6_layer = softmaxLayer('Name','S6_layer');
```

```
%  ------------------------------------
%  CAPA 7    C7: capa de clasificación
%  ------------------------------------

%C7 classificationLayer()
C7_layer= classificationLayer('Name','C7_layer');




% Imprime en pantalla la definición de las capas para comprobar
% cómo queda CADA CAPA de la red

I1_layer
C2_layer
R3_layer
P4_layer
F5_layer
S6_layer
C7_layer


% 2.2. CREA LA RED, ENSAMBLANDO LAS CAPAS RECIEN DEFINIDAS
% ********************************************************

red = [  I1_layer
         C2_layer
         R3_layer
         P4_layer
         F5_layer
         S6_layer
         C7_layer    ];


% Muestra la estructura de la red  para su comprobación

red

%       Da la siguiente salida con la estructura de la red
%       7x1 Layer array with layers:
%
%          1   'I1_layer'     Image Input             28x28x1 images
%          2   'C2_fn'        Convolution             20 5x5x1 convolutions with stride [1  1] and padd
%          3   'C3_RELU'      ReLU                    ReLU
%          4   'P4_maxpool'   Max Pooling             2x2 max pooling with stride [2  2] and padding [0
%          5   'F5_FC'        Fully Connected         10 fully connected layer
%          6   'S6_layer'     Softmax                 softmax
%          7   'C7_layer'     Classification Output   crossentropyex



% analyzeNetwork(red) % da una salida gráfica e identifica errores
```

```
%************************************************************************
%************************************************************************
%
%          3.  ENTRENAMIENTO  DE LA RED
%
%************************************************************************
%************************************************************************


% After defining the red (network structure), specify the training options.
%
% Set the options to default settings for the stochastic gradient descent
% with momentum. Set the maximum number of epochs at 15 (an epoch is a
% full training cycle on the whole training data), and start the training
% with an initial learning rate of 0.0001.



%          3.1.  ESPECIFICAR LAS OPCIONES PARA EL ENTRENAMIENTO
%************************************************************************


% Specify the Training Options
% 'sgdm' :stochastic gradient descent with momentum
options = trainingOptions('sgdm',... %
    'Momentum', 0.7, ... % valor de inercia a aplicar en el descenso por gradiente
    'MaxEpochs',50, ... % nº máximo de veces que pasará todo el conjunto de entrenamiento
    'MiniBatchSize',5,... % tamaño del minilote = nº de casos en cada iteración (= cada cuantos casos s
    'InitialLearnRate',0.0002 ...
    ,... % valor inicial de la tasa de aprendizaje
    'LearnRateSchedule','piecewise',...   %  la tasa de aprendizaje cambia durante el entrenamiento
    'LearnRateDropFactor', 1, ... % factor de reducción de la tasa de aprendizaje ...
    'LearnRateDropPeriod', 5, ...   %     .... que se aplica cada 5 épocas
    'ValidationData', testDigitData, ... % datos para validación durante el aprendizaje
    'ValidationFrequency',5,...  % cada cuántas iteraciones (minilotes) se validará la red
    'Plots','training-progress',...  % Dibujo a realizar; explicado en https://uk.mathworks.com/help/de
    'ExecutionEnvironment','gpu'); % Si dispone de tarjeta gráfica, poner 'gpu'

% Create a set of options for training a network using stochastic gradient
% descent with momentum. Reduce the learning rate by a factor of 0.2 every
% 5 epochs. Set the maximum number of epochs for training at 20, and
% use a mini-batch with 300 observations at each iteration.
% Specify a path for saving checkpoint networks after every epoch.

% options = trainingOptions('sgdm',...
%       'LearnRateSchedule','piecewise',...
%       'LearnRateDropFactor',0.2,...
%       'LearnRateDropPeriod',5,...
%       'MaxEpochs',15,...
%       'MiniBatchSize',300,...
```

```
%       'ExecutionEnvironment','cpu');



%     3.2.   ENTRENAR LA RED
%****************************

% Train the network you defined in red, using the training data and the
% training options you defined in the previous steps.
figure
axis([0 350 0 100])
[convnet,traininfo]= trainNetwork(trainDigitData,red,options);


% traininfo
% Information on the training, returned as a structure with the following fields.
%     TrainingLoss - Loss function value at each iteration
%     TrainingAccuracy - Training accuracy at each iteration if network is a classification network
%     TrainingRMSE - Training RMSE at each iteration if network is a regression network
%     BaseLearnRate - The learning rate at each iteration



%     3.3.   REVISAR EL RESULTADO DEL ENTRENAMIENTO
%*************************************************************************

% Revisar los nucleos de convolución aprendidos en la 1ª capa de convolución

convnet.Layers(2)

% Obtiene los valores de los nucleos de convolución aprendidos en la 1ª capa de convolución
w1 = convnet.Layers(2).Weights;

% Escribe en pantalla los valores de los pesos .
w1(:,:,1,2)
%w1(:,:,2,2)
%w1(:,:,3,2)

% Crea la imagen de los pesos, la amplia y la pinta en la pantalla.
% Scale and resize the weights for visualization
w1 = mat2gray(w1);
[s1,s2,s3,s4]= size (w1) ;

% Pinta la imagen de los pesos
w1x4(:,:,1,:) = imresize(w1(:,:,1,:),4,'Method','nearest');

% Display WEIGHTS of 2nd feature map  at the first layer  of network weights.
% There are 96 individual sets of weights in the first layer.
% w1(1,:,3,2)   (columna, fila, profundidad, nº de feature map)
figure
montage(w1x4,'BorderSize',[1 1],'BackgroundColor','yellow' )
title('FILTROS FINALES EN CAPA CONVOLUCIONAL zoom x 4')
%             I = imtile(mat2gray(act1),'GridSize',[4 8]);
```

```
%             figure
%             imshow(I,[]);impixelinfo
%             imshow(act1(:,:,3),[]);impixelinfo
% Display a montage of network weights. There are 96 individual sets of
% weights in the first layer.
% figure
% montage(w1x5)
% title('First convolutional layer weights')

%im = imread("image9001.png");
%imshow(im);
%imshow(imresize(im, [512 512], 'nearest'));

%act1 = activations(convnet,im,'C2_fn');

%sz = size(act1);
%act1 = reshape(act1,[sz(1) sz(2) 1 sz(3)]);
%I = imtile(mat2gray(act1),'GridSize',[5 4]);
%imshow(I);



%*************************************************************************
%*************************************************************************
%
%     4.  ANALISIS DEL RENDIMIENTO
%
%*************************************************************************
%*************************************************************************


%     4.1.  CLASIFICAR LAS IMÁGENES DE PRUEBA
%*************************************************************************


% Run the trained network on the test set that was not used to train
% the network and predict the image labels (digits).

% Clasificar las imágenes de test
YTest = classify(convnet,testDigitData);

TTest = testDigitData.Labels;


%     4.2.  CALCULAR INDICES DE RENDIMIENTO
%*************************************************************************


% Calcular e imprimir la exactitud obtenida en el conjunto de TEST.

accuracytest = sum(YTest == TTest)/numel(TTest)  ;
fprintf (1,' \r\n %-s %f8 \r\n', 'EXACTITUD (ACCURACY) CON DATOS TEST: ',accuracytest)  ;
```

```
% Calcular matriz de confusión con datos de test
fprintf (1,' \r\n %-s %f8 \r\n', 'MATRIZ DE CONFUSION. DATOS TEST: ' )  ;

confMat = confusionmat(TTest,YTest )

%         % Convert confusion matrix into percentage form
%         confMat = bsxfun(@rdivide,confMat,sum(confMat,2))




%     4.3.  MUESTRA ACTIVACIÓN DE UN 5
%*************************************************************************

 %filename='C:\Program Files\MATLAB\R2021b\toolbox\nnet\nndemos\nndatasets\DigitDataset\5\image4001.png
 %im = imread(filename);
 %imshow( im )
 %imshow(imresize(im, [512 512], 'nearest'))

 %act1 = activations(convnet,im,'C2_fn');
 %features = activations(convnet,im,'C2_fn')


%*************************************************************************
%  REGISTRAR EL TIEMPO DE EJECUCIÓN DEL PROGRAMA
%*************************************************************************

% abre y cierra todos los ficheros
fopen('all');
fclose ('all');


% registra tiempo de ejecución
datetime
toc
toc(timerVal_60)  % displays the time elapsed since the tic command corresponding to timerVal.
elapsedTime = toc(timerVal_60);  % returns the elapsed time since the tic command corresponding to time
%elapsedTime = toc ;% returns the elapsed time in a variable.
minuteselapsed=elapsedTime/60;
fprintf (1,'\r\n %-s %0.2f ','Minutos de ejecución: ', minuteselapsed );
fprintf (1,'\r\n %-s %0.2f \r\n','Horas de ejecución: ', minuteselapsed/60 );

%*************************************************************************
%  FIN
%*************************************************************************



function stop = stopTrainingAtThreshold(info,thr)

stop = false;
if info.State ~= "iteration"
    return
```

```
end

persistent iterationAccuracy

% Append accuracy for this iteration
iterationAccuracy = [iterationAccuracy info.TrainingAccuracy];

% Evaluate mean of iteration accuracy and remove oldest entry
if numel(iterationAccuracy) == 50
    stop = mean(iterationAccuracy) > thr;

    iterationAccuracy(1) = [];
end

end
```